

SAFE: Finding Sparse and Flat Minima to Improve Pruning

정기 논문 세미나 | 2026/05/18

인하대학교 항공우주제어시스템연구실

학부연구생 변 정 우



인하대학교
INHA UNIVERSITY



항공우주제어시스템연구실
Aerospace Control & Systems Laboratory

- **SAFE: Finding Sparse and Flat Minima to Improve Pruning**

- International Conference on Machine Learning (ICML) 2025, PMLR 267
- Authors: Dongyeop Lee, Kwanhee Lee, Jinseok Chung, Namhoon Lee
- Methods: SAFE, SAFE+
- Applications: image classification, LLM post-training pruning, noisy/corrupted data

1. Introduction

2. Background

3. Method

4. Experiments

5. Conclusion

■ 왜 pruning 이후 성능이 떨어지는가

- pruning의 필요성: hardware, databas의 한계, 복잡도-계산-메모리 자원 요구가 증가
- Excessive pruning: accuracy 감소 (일반화 및 성능 하락)
- Heuristic pruning: dense model의 동작을 안정적으로 보존하기 어려움
- Sparsity: 대부분의 parameter를 0으로 만드는 solution을 찾는 관점
- Main question: 어떻게 dense solution quality를 유지하며 sparsify할 것인가?

■ Main direction

- 임의의 sparse subnetwork가 아닌, sparse하면서도 flat한 solution을 탐색하는 방향을 제안

▪ Sparse and Flat Solution

- Solution landscape의 flatness를 활용해 model의 generalization 성능을 설명
 - **SAM: local weight neighborhood 안의 worst-case loss를 최소화하며 이 아이디어를 구현 (generalization 성능 개선 및 label noise에서의 robustness 확인)
 - (**SHARPNESS-AWARE MINIMIZATION FOR EFFICIENTLY IMPROVING GENERALIZATION)
- Sharpness-aware training에 따른 model compressibility나 sparsification에 관한 연구는 아직 초기 단계

▪ Main methods (SAFE / SAFE+)

- Training 과정에서 sharpness와 sparsity를 함께 다루기에 기존 sharpness-aware optimization 문제를 sparsity-constrained optimization 문제로 다룸
- SAFE = SAM + Sparsity constraint
- Lagrangian dual 기반 접근 / ADMM
- Sparse solution의 flatness와 성능 향상을 확인
- Noise robustness 및 SAM 계열 방법과의 비교

▪ pruning 시점

- Pruning은 efficiency/accuracy trade-off에 따라 pre-, during-, post-training에서 수행 가능
- Focus: 정확한 sparse solution을 얻기 위한 during-training pruning

Stage	When useful
Pre-training	Training efficiency
During-training	Best sparse performance
Post-training	Large pre-trained models

▪ Sparsity (constrained optimization 관점)

- Sparsity constraint를 가진 optimization problem을 푸는 방식 (non-zero parameter 수를 제한하는 L0 norm constraint)
- 하지만 이 문제는 정확히 풀기 어려움 (L0-constrained problem이 combinatorial, non-convex, discrete, ...)
- L0 norm을 완화하기 위한 LASSO, FISTA와 같은 최적화 기법, iterative hard thresholding, 2차 근사 기반 OBD/OBS 등이 사용됨

$$\min_{\|x\|_0 \leq d} f(x)$$

▪ Flat minima

- Weight 주변 작은 neighborhood에서도 loss가 낮게 유지되는 지점
- Sharp하지 않은 해 (= flat)

▪ SAM (Sharpness-Aware Minimization)

- SAM: 작은 perturbation neighborhood 안의 worst-case training loss를 최소화
- Neighborhood radius ρ : local sharpness를 얼마나 강하게 측정할지 결정
- Inner maximization은 first-order ascent step으로 근사해 ϵ^* 를 구함
- 이후 model은 $w + \epsilon^*$ 에서 평가한 gradient로 업데이트됨

Property	Sharp minima	Flat minima
Local curvature	High	Low
Perturbation sensitivity	High	Low
Generalization	Often worse	Often better
Pruning implication	Fragile sparse model	Robust sparse model

$$\min_x \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon)$$

$$\epsilon^*(x) = \rho \frac{\nabla f(x)}{\|\nabla f(x)\|_2}$$

- 1) local ascent로 ϵ^* 탐색
- 2) $\nabla L(w + \epsilon^*)$ 로 descent

■ SAM 이후 남는 문제

- SAM은 flat minima를 찾지만, sparse model을 직접 만들지는 않음
- Flatness 개선이 pruning 이후 성능 보존이 자동으로 보장되지는 않음
- SAM으로 학습된 dense model이 항상 더 compressible해지는 것은 아님

■ CrAM의 방향성

- CrAM은 SAM 학습 과정에서 model compressibility가 약화될 수 있다는 점에 주목
- 학습 과정에서 compression-aware한 제약을 추가하여, pruning 이후 성능 저하를 줄이고자 함

■ SAFE의 방향성

- SAFE는 compressibility를 간접적으로 높이기보다, sparse solution의 sharpness를 직접 줄이는 방향을 선택
- 목표는 compressible dense model이 아니라, 성능을 유지할 수 있는 flat sparse minimum을 찾는 것
- 따라서 pruning을 sparsity constraint와 flatness objective가 결합된 optimization problem으로 재정의

■ SAFE: Problem formulation

- x : candidate sparse network
 d : 보존할 parameter 수
 ρ : sharpness를 측정하는 local neighborhood 크기
- SAFE: SAM의 loss minimization에 L0 sparsity constraint를 결합
 - non-zero 원소 개수가 d 개 이하이면서, neighborhood 전체에서 loss가 낮은 해를 탐색
 - 기존 sharpness-aware optimization 문제를 sparsity-constrained optimization 문제로 다룸 (sparse-flat problem)

$$\text{SAM: } \min_x \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon)$$

$$\text{SAFE: } \min_{\|x\|_0 \leq d} \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon)$$

▪ SAFE: Augmented Lagrangian 기반 접근

- Lagrangian duality: L0 constraint가 discrete하기 때문에 다루기 어려움
PGD: highly non-convex neural objective에서 불안정
- λ : penalty parameter
- 변수 분리: x 는 flatness-aware minimization (flat한 low-loss point 탐색)
 z 는 projection operation (sparsity projection을 담당, L0 sparsity constraint 만족)
 u 는 scaled dual variable ($u = \frac{y}{\lambda}$, step size: λ , 반복 중 x - z residual 누적)

sparse flat problem: $\min_{\|x\|_0 \leq d} \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon)$

Variable Splitting: $\min_{x,z} F(x) + G(z) \quad \text{s.t.} \quad x = z$

$$\min_{x,z} \left[\max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon) \right] + [I_{\{\|\cdot\|_0 \leq d\}}(z)] \quad \text{s.t.} \quad x = z$$

$$I_{\|\cdot\|_0 \leq d}(z) := \begin{cases} 0 & \text{if } \|z\|_0 \leq d \\ \infty & \text{else} \end{cases}$$

▪ SAFE: Augmented Lagrangian 기반 접근

- 다음 x-step의 penalty term $\|x - z + u\|^2$ 에 반영
- 수식 표현 $\rightarrow$ ADMM와 유사한 형태로 정리 (ADMM의 조건 강제 식: $y^T(x - z) + \frac{\lambda}{2}\|x - z\|_2^2$)
- 복잡한 L0 제약 자체를 직접 풀지 않고, z-update의 hard-thresholding projection으로 처리
- 변수 분리: x는 flatness-aware minimization (flat한 low-loss point 탐색)
z는 projection operation (sparsity projection을 담당, L0 sparsity constraint 만족)
u는 scaled dual variable ($u = \frac{y}{\lambda}$, step size: λ , 반복 중 $x = z$ residual 누적)

$$\text{Augmented Lagrangian: } \mathcal{L}(x, z, u) = \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon) + I_{\{\|\cdot\|_0 \leq d\}}(z) + \frac{\lambda}{2}\|x - z + u\|_2^2 - \frac{\lambda}{2}\|u\|_2^2$$

$$x_{k+1} = \arg \min_x \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon) + \frac{\lambda}{2}\|x - z_k + u_k\|_2^2$$

$$z_{k+1} = \text{proj}_{\|\cdot\|_0 \leq d}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

■ SAFE: x-minimization

- ϵ 에 대한 inner maximization: first-order Taylor expansion으로 근사
→ SAM-perturbation $\epsilon^*(x)$ 를 생성
- x-step은 SAM-flatness minimization에
ADMM consistency penalty를 추가한 형태
- x는 단순히 low-loss point를 찾는 것이 아닌,
sparse projection z_k 와의 일관성을 유지하면서 flat point 탐색
- x-gradient = SAM-gradient + ADMM penalty gradient

$$x_k^{(t+1)} = x_k^{(t)} - \eta^{(t)} \nabla_x J(x_k^{(t)})$$

(J(x)는 objective function이므로)

$$x_{k+1} = \arg \min_x \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon) + \frac{\lambda}{2} \|x - z_k + u_k\|_2^2$$

$$\epsilon^*(x) \approx \operatorname{argmax}_{\|\epsilon\|_2 \leq \rho} f(x) + \epsilon^\top \nabla f(x) = \rho \frac{\nabla f(x)}{\|\nabla f(x)\|_2}$$

$$x_{k+1} = \arg \min_x [f(x + \epsilon^*(x)) + \frac{\lambda}{2} \|x - z_k + u_k\|_2^2]$$

$$\begin{aligned} & \nabla_x \left(f(x + \epsilon^*(x)) + \frac{\lambda}{2} \|x - z_k + u_k\|_2^2 \right) \\ & \approx \nabla f \left(x + \rho \frac{\nabla f(x)}{\|\nabla f(x)\|_2} \right) + \lambda(x - z_k + u_k) \end{aligned}$$

$$x_k^{(t+1)} = x_k^{(t)} - \eta^{(t)} \left(\nabla f \left(x_k^{(t)} + \rho \frac{\nabla f(x_k^{(t)})}{\|\nabla f(x_k^{(t)})\|_2} \right) + \lambda(x_k^{(t)} - z_k + u_k) \right)$$

SAFE+: Generalized projection으로 확장

- SAFE projection: Euclidean norm 기반
→ 제거 비용: v_i^2 인 magnitude pruning
- SAFE+: Euclidean norm을 weighted metric P 로 대체
→ 제거 비용을 $P_i v_i^2$ 로 일반화
- P 에 curvature, gradient, activation 정보를 넣어 parameter importance를 projection에 반영
(실제 pruning에서 쓰이는 더 정보량 높은 score들을 framework 안에 흡수시키는 역할)

$$x_{k+1} = \arg \min_x \max_{\|\epsilon\|_2 \leq \rho} f(x + \epsilon) + \frac{\lambda}{2} \|x - z_k + u_k\|_2^2$$

$$z_{k+1} = \text{proj}_{\|\cdot\|_0 \leq d}^P(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

$$\begin{aligned} z_{k+1} &= \text{proj}_{\|\cdot\|_0 \leq d}^P(x_{k+1} + u_k) \\ &:= \arg \min_{\|z\|_0 \leq d} \frac{1}{2} \|z - (x_{k+1} + u_k)\|_P^2 \\ &= \arg \min_{\|z\|_0 \leq d} \frac{1}{2} (z - (x_{k+1} + u_k))^T \mathbf{P} (z - (x_{k+1} + u_k)) \end{aligned}$$

P 선택	대응 관점
I	Magnitude pruning / SAFE
$\text{diag}(\nabla^2 f)$	Optimal Brain Damage; Second order pruning method
$\text{diag}(\nabla f \nabla f^T)$	SNIP; First order pruning method
$\text{diag}(A^T A)$	Wanda; layer-wise pruning

Algorithm 1 SAFE and SAFE⁺ algorithms

Require: Target parameter count d , total train iteration T , dual-update interval K , learning rate $\eta^{(t)}$, perturbation radius ρ , penalty parameter λ , importance matrix $\mathbf{P}$.

```

1: Initialize  $x^{(0)}$ 
2:  $u = \mathbf{0}$ 
3: for  $t$  in  $T$  do
4:   if  $t \bmod K = 0$  then
5:     if SAFE then
6:        $z = \text{proj}_{\|\cdot\|_0 \leq d}(x^{(t+1)} + u)$ 
7:     else if SAFE+ then
8:        $z = \text{proj}_{\|\cdot\|_0 \leq d}^{\mathbf{P}}(x^{(t+1)} + u)$ 
9:     end if
10:     $u = u + x^{(t+1)} - z$ 
11:  end if
12:   $x^{(t+1/2)} = x^{(t)} - \eta^{(t)} \nabla f \left( x^{(t)} + \rho \cdot \frac{\nabla f(x^{(t)})}{\|\nabla f(x^{(t)})\|_2} \right)$ 
13:   $x^{(t+1)} = x^{(t+1/2)} - \eta^{(t)} \lambda (x^{(t)} - z + u)$ 
14: end for
15: return  $\text{proj}_{\|\cdot\|_0 \leq d}(x^{(T)})$ 


```

- 1) $t=0, \dots, t=T$ 로 x-subproblem을 풀어 x를 업데이트
- 2) 매 K step마다 SAFE/SAFE+ projection을 통해 sparse estimate z를 갱신
- 3) x-z residual을 줄이도록 dual variable u에 업데이트
- 4) x-update는 flatness-aware gradient step과 sparsity penalty step으로 구성 (line 12, 13)
- 5) penalty term은 x가 z에 점진적으로 가까워지도록 유도 ($\lambda(x^{(t)} - z + u)$)
- 6) $x^{(T)}$ 를 sparsity constraint에 projection하여 sparse model을 반환


* 초기에는 sparsity penalty를 약하게 두고, 이후 λ 를 증가시켜 급격한 pruning 효과를 완화

▪ Sparse and flat solution으로의 수렴


- SAFE는 많은 weight를 0 근처로 모으면서 동시에 local sharpness를 낮춤
- Dense training 대비 SAFE는 weight distribution을 0 주변에 훨씬 더 집중시킴
- ADMM 대비 SAFE는 더 flat한 loss landscape와 더 작은 largest Hessian eigenvalue를 보임
- 논문 수치상 sharpness는 ADMM ≈ 0.20 , SAFE ≈ 0.09




(a) Dense training



(b) SAFE







(c) ADMM



(d) SAFE

Image classification 평가 (CIFAR-10, 100)

- sparsity 구간: 90%, 95%, 98%, 99%, 99.5%
- Task가 어렵고 network가 더 sparse해질수록 SAFE의 advantage가 커짐
- sparsity가 극단적으로 높아질수록 flatness의 효과가 더 뚜렷해짐
- aggressive sparsity에서 어려운 model을 pruning할 때 flat sparse minima가 특히 중요함
- CIFAR-100은 가장 어렵고 sparse한 regime에서 SAFE의 장점이 가장 선명하게 드러남



- Large language model pruning 평가
 - Perplexities (mean $\pm$ std) of LLaMa models
 - LLaMA-2 7B/13B, LLaMA-3 8B
sparsity pattern: 50%, 60%, 4:8, 2:4
 - SAFE는 SparseGPT, Wanda, ALPS 같은 강한 post-training pruning baseline과 비교하여 높은 성능을 보임
 - SAFE+는 generalized projection이 더 강한 saliency information을 반영할 수 있어 모든 Method 비교에서 제일 높은 성능을 보임

$$\text{Perplexity}(x_{1:N}) = \exp \left(-\frac{1}{N} \sum_{i=1}^N \log p(x_i | x_{<i}) \right)$$

Sparsity	Method	LLaMa-2				LLaMa-3	
		7B		13B		8B	
		Wikitext/C4		Wikitext/C4		Wikitext/C4	
0%	Dense	5.47	/ 7.26	4.88	/ 6.72	6.23	/ 9.53
50%	Magnitude	16.03	/ 21.33	6.82	/ 9.37	134.20	/ 273.3
	SparseGPT	6.99 $\pm$ 0.03	/ 9.20 $\pm$ 0.03	6.06 $\pm$ 0.03	/ 8.20 $\pm$ 0.01	9.36 $\pm$ 0.11	/ 13.96 $\pm$ 0.02
	Wanda	6.92 $\pm$ 0.01	/ 9.23 $\pm$ 0.00	5.98 $\pm$ 0.01	/ 8.28 $\pm$ 0.01	9.71 $\pm$ 0.03	/ 14.88 $\pm$ 0.04
	ALPS	6.87 $\pm$ 0.01	/ 8.98 $\pm$ 0.00	5.96 $\pm$ 0.02	/ 8.09 $\pm$ 0.04	9.05 $\pm$ 0.12	/ 13.40 $\pm$ 0.06
	SAFE	6.78 $\pm$ 0.01	/ 8.93 $\pm$ 0.00	5.76 $\pm$ 0.01	/ 7.85 $\pm$ 0.02	9.59 $\pm$ 0.06	/ 14.60 $\pm$ 0.04
	SAFE+	6.56 $\pm$ 0.01	/ 8.71 $\pm$ 0.00	5.67 $\pm$ 0.01	/ 7.74 $\pm$ 0.01	8.62 $\pm$ 0.06	/ 13.26 $\pm$ 0.06
60%	Magnitude	1864	/ 2043	11.81	/ 14.62	5335	/ 7438
	SparseGPT	10.19 $\pm$ 0.08	/ 12.86 $\pm$ 0.05	8.31 $\pm$ 0.09	/ 10.85 $\pm$ 0.09	15.46 $\pm$ 0.40	/ 21.25 $\pm$ 0.18
	Wanda	10.75 $\pm$ 0.07	/ 13.87 $\pm$ 0.01	8.43 $\pm$ 0.07	/ 11.55 $\pm$ 0.01	22.06 $\pm$ 0.19	/ 32.28 $\pm$ 0.37
	ALPS	9.55 $\pm$ 0.00	/ 11.24 $\pm$ 0.03	7.54 $\pm$ 0.03	/ 9.87 $\pm$ 0.05	14.03 $\pm$ 0.35	/ 18.72 $\pm$ 0.15
	SAFE	9.20 $\pm$ 0.04	/ 11.51 $\pm$ 0.04	7.18 $\pm$ 0.03	/ 9.59 $\pm$ 0.03	15.90 $\pm$ 0.25	/ 22.26 $\pm$ 0.16
	SAFE+	8.30 $\pm$ 0.06	/ 10.59 $\pm$ 0.00	6.78 $\pm$ 0.04	/ 9.02 $\pm$ 0.15	12.18 $\pm$ 0.22	/ 17.30 $\pm$ 0.02
4:8	Magnitude	15.91	/ 31.61	7.32	/ 9.96	212.5	/ 336.3
	SparseGPT	8.42 $\pm$ 0.05	/ 10.73 $\pm$ 0.03	7.02 $\pm$ 0.06	/ 9.33 $\pm$ 0.04	12.16 $\pm$ 0.20	/ 17.36 $\pm$ 0.06
	Wanda	8.64 $\pm$ 0.03	/ 11.35 $\pm$ 0.01	7.01 $\pm$ 0.02	/ 9.70 $\pm$ 0.03	13.84 $\pm$ 0.04	/ 21.14 $\pm$ 0.06
	ALPS	8.11 $\pm$ 0.09	/ 10.21 $\pm$ 0.04	6.81 $\pm$ 0.07	/ 9.33 $\pm$ 0.04	11.38 $\pm$ 0.17	/ 16.10 $\pm$ 0.10
	SAFE	8.21 $\pm$ 0.01	/ 10.61 $\pm$ 0.04	6.60 $\pm$ 0.02	/ 8.95 $\pm$ 0.02	12.15 $\pm$ 0.14	/ 17.90 $\pm$ 0.15
	SAFE+	7.59 $\pm$ 0.03	/ 9.88 $\pm$ 0.01	6.37 $\pm$ 0.03	/ 8.61 $\pm$ 0.01	10.51 $\pm$ 0.13	/ 15.67 $\pm$ 0.02
2:4	Magnitude	37.77	/ 74.70	8.88	/ 11.72	792.8	/ 2245
	SparseGPT	11.00 $\pm$ 0.20	/ 13.54 $\pm$ 0.03	8.78 $\pm$ 0.09	/ 11.26 $\pm$ 0.11	15.87 $\pm$ 0.32	/ 22.45 $\pm$ 0.12
	Wanda	12.17 $\pm$ 0.02	/ 15.60 $\pm$ 0.11	9.01 $\pm$ 0.04	/ 12.40 $\pm$ 0.01	23.03 $\pm$ 0.38	/ 34.91 $\pm$ 0.31
	ALPS	9.99 $\pm$ 0.19	/ 12.04 $\pm$ 0.04	8.16 $\pm$ 0.17	/ 10.35 $\pm$ 0.18	14.53 $\pm$ 0.33	/ 19.74 $\pm$ 0.18
	SAFE	10.53 $\pm$ 0.13	/ 13.20 $\pm$ 0.07	7.64 $\pm$ 0.05	/ 10.10 $\pm$ 0.01	17.49 $\pm$ 0.27	/ 24.45 $\pm$ 0.13
	SAFE+	8.96 $\pm$ 0.07	/ 11.34 $\pm$ 0.03	7.20 $\pm$ 0.04	/ 9.52 $\pm$ 0.01	13.39 $\pm$ 0.23	/ 19.03 $\pm$ 0.01

▪ Noisy data에 대한 robustness

- sparsity 구간: 70%, 80%, 90%, 95%, / 90%, 95%, 98%, 99%, 99.5%
 - SAFE는 training 중 label noise와 inference time의 common, adversarial corruption에서 robustness를 개선
 - noisy-label setting에서 ADMM 대비 대략 +10%~+30% accuracy improvement를 보임
- sparse-flat solution은 clean 성능뿐 아니라 noise robustness에서도 이점을 보임

Sparsity	Method	Noise ratio		
		25%	50%	75%
70%	ADMM	77.00 $\pm$ 0.91	59.18 $\pm$ 0.55	32.62 $\pm$ 0.89
	SAFE	90.58 $\pm$ 0.30	86.51 $\pm$ 0.16	67.01 $\pm$ 0.54
80%	ADMM	76.18 $\pm$ 0.56	62.67 $\pm$ 0.38	32.86 $\pm$ 1.12
	SAFE	91.25 $\pm$ 0.12	86.55 $\pm$ 0.07	66.49 $\pm$ 0.56
90%	ADMM	79.40 $\pm$ 0.12	66.64 $\pm$ 0.13	36.84 $\pm$ 0.94
	SAFE	90.68 $\pm$ 0.21	86.49 $\pm$ 0.06	64.72 $\pm$ 0.61
95%	ADMM	77.71 $\pm$ 0.52	67.10 $\pm$ 1.37	39.68 $\pm$ 1.44
	SAFE	89.86 $\pm$ 0.11	85.18 $\pm$ 0.15	64.25 $\pm$ 0.36

Sparsity	Method	Common corruption (avg.)		Adversarial	
		intensity=3	intensity=5	l_∞ -PGD	l_2 -PGD
90%	ADMM	70.06 $\pm$ 0.03	52.01 $\pm$ 0.38	49.81 $\pm$ 1.02	49.71 $\pm$ 1.06
	SAFE	73.98 $\pm$ 0.09	55.11 $\pm$ 0.27	56.43 $\pm$ 1.03	56.36 $\pm$ 1.11
95%	ADMM	68.87 $\pm$ 0.25	50.56 $\pm$ 0.07	49.84 $\pm$ 1.78	49.68 $\pm$ 1.79
	SAFE	72.92 $\pm$ 0.41	54.86 $\pm$ 0.51	51.40 $\pm$ 0.89	51.36 $\pm$ 0.94
98%	ADMM	65.46 $\pm$ 0.24	48.65 $\pm$ 0.04	43.33 $\pm$ 1.59	43.42 $\pm$ 1.60
	SAFE	68.20 $\pm$ 0.47	49.96 $\pm$ 0.83	43.34 $\pm$ 0.90	43.41 $\pm$ 1.03
99%	ADMM	59.21 $\pm$ 0.47	43.81 $\pm$ 0.44	30.29 $\pm$ 0.64	30.32 $\pm$ 0.58
	SAFE	66.02 $\pm$ 0.56	49.34 $\pm$ 1.03	43.70 $\pm$ 1.28	32.70 $\pm$ 1.28
99.5%	ADMM	55.72 $\pm$ 0.44	41.55 $\pm$ 0.78	23.25 $\pm$ 1.92	23.25 $\pm$ 1.85
	SAFE	56.58 $\pm$ 0.36	42.27 $\pm$ 0.63	29.48 $\pm$ 0.68	29.45 $\pm$ 0.74

▪ 다른 SAM-based pruner와의 비교

- IMP+SAM, CrAM, CrAM+, SAFE, SAFE+SG
- SAFE는 IMP+SAM_{linear}, IMP+SAM_{cubic}, CrAM에 대해 대부분의 high-sparsity 구간에서 상회
- 특히 SAFE+SG는 99%, 99.5% sparsity에서 CrAM+보다 높은 성능을 보이며 extreme-sparsity에 강함
- 즉, SAFE+SG는 SAFE에서 sparse gradient($\nabla f(C(x))$) 결합 시 극단적 pruning에서 성능이 강화됨

Method	Sparsity			
	95%	98%	99%	99.5%
IMP+SAM _{linear}	80.30 $\pm$ 0.12	36.03 $\pm$ 4.19	18.30 $\pm$ 2.80	13.80 $\pm$ 0.52
IMP+SAM _{cubic}	92.50 $\pm$ 0.05	89.24 $\pm$ 0.06	83.74 $\pm$ 0.14	73.73 $\pm$ 0.30
CrAM	90.18 $\pm$ 1.80	69.53 $\pm$ 12.36	45.17 $\pm$ 20.86	10.00 $\pm$ 0.00
CrAM ⁺	93.62 $\pm$ 0.06	91.75 $\pm$ 0.41	<u>88.82</u> $\pm$ 0.18	<u>81.30</u> $\pm$ 0.56
SAFE	<u>92.59</u> $\pm$ 0.09	89.58 $\pm$ 0.10	87.47 $\pm$ 0.07	79.55 $\pm$ 0.13
SAFE+SG	92.40 $\pm$ 0.06	<u>90.09</u> $\pm$ 0.13	89.13 $\pm$ 0.06	85.85 $\pm$ 0.09

■ Conclusion

- SAFE는 pruning을 단순히 weight를 제거하는 문제가 아니라, sparsity와 flatness를 동시에 만족하는 constrained optimization problem으로 재정의함
- Augmented Lagrangian을 통해 optimization framework로 sparse and flat solution을 탐색함
- SAFE+는 projection operation을 일반화하여 기존 SAFE를 확장하고, 더 풍부한 saliency information을 pruning 과정에 반영할 수 있음
- Image classification, LLM pruning, noisy-data setting 등 standard benchmarks에서 SAFE는 강한 pruning baseline 대비 generalization performance를 일관되게 개선함
- training 및 inference 단계의 data noise에 대해서도 robust함을 보임

■ 실용적 접근

- 공격적인 pruning에서 성능 저하를 줄이려면, 단순히 sparsity만 강제하는 것보다 sparse and flat minima를 함께 탐색하는 것이 더 효과적
- SAFE는 SAM-inspired baseline과 비교해도 auxiliary technique에 크게 의존하지 않고, sparse-flat optimization 자체의 효과를 보여줌

THANK YOU



인하대학교
INHA UNIVERSITY



항공우주제어시스템연구실
Aerospace Control & Systems Laboratory